Angewandte KI & KI-Engineering (AKE) · Block E – Capstone

# Capstone-Projekte: Themen und Anforderungen

Selbststudium vor der Themenwahl · acht Themen im Detail

Stefan Gnaase · PHWT · Wintersemester 2026/27

# Organisatorisches – Capstone

Alle Termine und Abgabewege an einer Stelle – der Rest des Decks nennt nur Wochen

| | |
|---|---|
| **Gruppen** | Dieselben Gruppen wie für die Lehreinheiten (Reverse Classroom) |
| **Themenwahl** | **bis Woche 5 (05.11.)**: Erst- und Zweitwahl je Gruppe |
| **Thema 8** | Eigenes Thema: Abstimmung mit Dozent bis 05.11. |
| **Thema 2** | MIMIC-Zugang bei PhysioNet **sofort** beantragen – vor der Wahl, das Credentialing dauert |
| **Kickoff** | **Woche 6 (12.11.)**: Datenkonzept · ab dann ist der 2-SWS-Block feste Projektstunde |
| **Checkpoints** | **Woche 8 (26.11.)** und **Woche 10 (10.12.)**: je ca. 10 Min. pro Gruppe in der Projektstunde |
| **Abschluss** | **Woche 11 (17.12.)**: 15-Min.-Präsentation mit Live-Demo · Abgabe Repository-Link und Model Card in Vorwoche |

# Worum geht es?

Ein KI-System von den Rohdaten bis zum verantworteten Service – eigenverantwortlich im Team

| Station | 1 Daten | 2 Modell | 3 Deployment | 4 Monitoring | 5 Verantwortung |
|---|---|---|---|---|---|
| **Gelernt im Thema** | Daten-Engineering für ML | Grundlagen-Wochen, MLOps | MLOps: Vom Notebook zum Produktivsystem | Monitoring, Drift & Lifecycle | Trustworthy AI, Strategie |
| **Geführt: Trägermodell** | Imagenette mit DVC versionieren | ResNet-18, Transfer Learning | FastAPI + Docker | Drift durch Beleuchtung | Grad-CAM, SHAP, Mini-Model-Card |
| **Selbst: Ihr Capstone** | eigene Quelle, eigenes Datenkonzept | Baseline + eigenes Modell | eigener Service im Container | eigenes Drift-Szenario | XAI, AI-Act-Einordnung, Model Card |

# Pflichtbausteine

Jedes Projekt deckt die ganze Kette ab – Tiefe statt Breite in jedem Baustein

## 1 Daten

- Datenkonzept: Quelle, Lizenz, Umfang, Qualität
- Versionierung mit DVC, reproduzierbare Pipeline

→ Daten-Engineering für ML

## 2 Modell

- Baseline + mindestens ein ML/DL-Modell
- sauberer Split bzw. Backtest, Experimente mit MLflow

→ Grundlagen-Wochen, MLOps

## 3 Deployment

- FastAPI-Service mit Tests
- Dockerfile – Fallback: Build in GitHub Actions

→ MLOps

## 4 Monitoring

- Logging der Anfragen
- Drift-Szenario simulieren und erkennen

**Pflicht für 4er-Gruppen (3er: Logging)**

## 5 Verantwortung

- XAI-Analyse, Fairness wo Menschen betroffen
- EU-AI-Act-Einordnung + Model Card

→ Trustworthy AI

## 6 Business Case

- Nutzen, Kosten, Build vs. Buy in einer Rechnung
- für wen lohnt sich das System?

→ KI-Strategie & Geschäftsmodelle

# Abgabe und Bewertung

Vier Ergebnisse, 100 Punkte – Modellgröße allein bringt keine Punkte

## Was Sie abgeben

**1 Code-Repository**

README mit Reproduktionsanleitung, DVC-Pipeline, Tests, Dockerfile

**2 Live-Demo**

der Service beantwortet in der Präsentation echte Anfragen

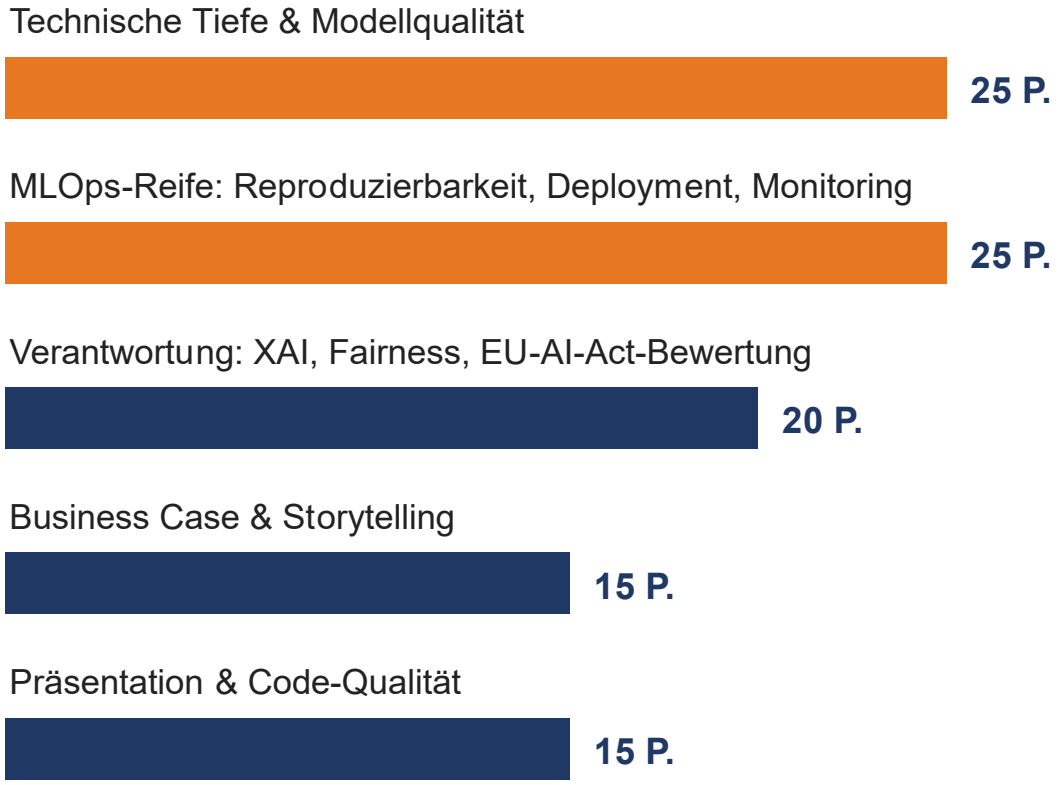
**3 Model Card**

Zweck, Daten, Metriken, Grenzen, Fairness, AI-Act-Einordnung

**4 Präsentation**

15 Minuten + Fragen: Problem → Modell → Deployment → Verantwortung

## Bewertungsraster (100 Punkte)




! Ein vollständiger, reproduzierbarer Durchlauf zählt mehr als ein großes Modell ohne Deployment. !

# Meilensteine

Die Vorlesung liefert jede Woche genau den Baustein, den Ihr Projekt als Nächstes braucht

| 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|
| Woche 5 | Woche 6 | Woche 8 | Woche 10 | Woche 11 |
| **Themenwahl** | **Kickoff** | **Checkpoint 1** | **Checkpoint 2** | **Abschluss** |
| • Erst- und Zweitwahl<br>• Thema 8: Abstimmung<br>• Thema 2: Zugang beantragt | • Datenkonzept: Quelle, Lizenz, Umfang<br>• Repo angelegt, Rollen verteilt | • Daten mit DVC versioniert<br>• Baseline-Ergebnis steht<br>• erstes Modell trainiert | • Service läuft im Container<br>• Drift-Szenario bzw. Logging<br>• erste XAI-Ergebnisse, Model-Card-Entwurf | • Präsentation + Live-Demo<br>• Repo und Model Card final<br>• Business Case |

## Parallel in der Vorlesung

| Daten-Engineering | MLOps & Deployment | Monitoring & Drift | Trustworthy AI | Strategie & Business |
|---|---|---|---|---|

# Rahmenbedingungen

Alle Themen laufen auf Ihrem Laptop – der Rechencluster ist Zugabe, nicht Voraussetzung

## 1 Rechner

- Referenz: 4 Kerne, 8 GB RAM, keine GPU
- Basis-Variante muss darauf laufen
- rechenintensive Schritte einmal rechnen und cachen
- Bewertung honoriert Modellgröße nicht

## 2 Sprachmodelle

- LLM lokal ≤ 1 B Parameter: Qwen2.5-0.5B, SmolLM2-360M
- Embeddings: MiniLM, Vektor-DB lokal (Chroma/FAISS)

## 3 Daten und Recht

- Lizenz prüfen und im README nennen
- personenbezogene oder lizenzbeschränkte Daten nie ins Git – DVC mit lokalem Remote
- MIMIC: keine Weitergabe, keine Online-Dienste
- Prototyp ≠ Inverkehrbringen: AI-Act-Bewertung „als ob“

# Die acht Themen

Sieben ausgearbeitete Vorschläge – oder ein eigenes Thema

## 1 Smart Energy

Ein Stadtwerk braucht morgen früh die Last von übermorgen – Stunde für Stunde, für das ganze Quartier

**EU AI Act: minimal**

## 2 Klinik-Triage

Bei Ankunft vergibt die Pflege eine Dringlichkeitsstufe – ein Assistent soll einen begründeten Vorschlag machen

**EU AI Act: hoch**

## 3 Recruiting-Fairness

Ein Unternehmen will Bewerbungsprofile automatisch vorsortieren – Sie prüfen, ob das fair geht

**EU AI Act: hoch**

## 4 Predictive Maintenance

Warten, bevor etwas kaputtgeht – aber nicht so früh, dass man intakte Teile wegwirft

**EU AI Act: meist minimal**

## 5 RAG-Compliance

Fragen zu AI Act und DSGVO beantworten – mit wörtlicher Quelle statt erfundener Paragrafen

**EU AI Act: Transparenz**

## 6 CV-Qualitätskontrolle

Kratzer, Risse, Verfärbungen erkennen – obwohl es fast nur Bilder von Gutteilen gibt

**EU AI Act: minimal**

## 7 Customer-Service-Agenten

Wo ist meine Bestellung? Wie storniere ich? – Agenten mit Werkzeugen beantworten Standardanfragen

**EU AI Act: Transparenz**

## 8 Eigenes Thema

Ihr Use Case – wenn alle fünf Stationen abgedeckt werden können

**EU AI Act: selbst einordnen**

# Themen im Vergleich

Einschätzung relativ zueinander – ●●●●● = hoch

| # | Thema | Daten | Methodischer Schwerpunkt | AI Act | Programmieren | Datenzugang | Doku |
|---|---|---|---|---|---|---|---|
| 1 | **Smart Energy** | Zeitreihe | Prognose, Anomalien | minimal | ●●●○○ | ●○○○○ | ●●○○○ |
| 2 | **Klinik-Triage** | Text + Tabelle | Klassifikation, Kalibrierung | hoch | ●●●○○ | ●●●●● | ●●●●● |
| 3 | **Recruiting-Fairness** | Text | NLP, Fairness-Audit | hoch | ●●●○○ | ●○○○○ | ●●●●● |
| 4 | **Predictive Maintenance** | Sensor-Zeitreihe | RUL, Survival, Edge | minimal | ●●●●○ | ●○○○○ | ●●○○○ |
| 5 | **RAG-Compliance** | Rechtstexte | Retrieval, LLM-Eval | Transparenz | ●●●●○ | ●○○○○ | ●●●○○ |
| 6 | **CV-Qualitätskontrolle** | Bilder | Anomalieerkennung, Drift | minimal | ●●●○○ | ●●○○○ | ●●○○○ |
| 7 | **Customer-Service-Agenten** | Dialoge, synthetisch | Agenten, Tool-Use | Transparenz | ●●●●● | ●○○○○ | ●●●○○ |

# Wie wählen?

Vier Fragen, die Ihre Gruppe vor der Wahl ehrlich beantworten sollte

### 1 Interesse

Welches Problem würden Sie auch nach sieben Wochen noch gern lösen? Was passt zu Studiengang und Berufsziel?

### 2 Kompetenzmix

Wer programmiert sicher, wer rechnet, wer schreibt und präsentiert? Themen mit ●●●●● Programmieraufwand brauchen mindestens zwei sichere Programmierer:innen.

### 3 Datenzugang

Liegen die Daten heute frei vor? Jede Woche Warten auf Zugang fehlt am Ende beim Deployment.

### 4 Compliance-Aufwand

Hochrisiko heißt: Risikoanalyse, Daten-Governance, Aufsichtskonzept, ausführliche Model Card – lehrreich, aber aufwendig.

# Thema 1

## Smart Energy: Lastprognose für ein Stadtquartier

**Kernfrage** Wie genau lässt sich ein Quartier vorhersagen – und wie viel Privatsphäre kostet das?

**Thema 1** – Thema 2 – Thema 3 – Thema 4 – Thema 5 – Thema 6 – Thema 7 – Thema 8

# Thema 1 · Steckbrief

Ein Stadtwerk braucht morgen früh die Last von übermorgen – Stunde für Stunde, für das ganze Quartier

| | |
|---|---|
| **Szenario** | Ein Stadtwerk plant Einkauf, Speicher und Netz für ein Quartier mit Wohnungen, Gewerbe und einer Schule. Dafür braucht es die Last des Folgetags und eine Warnung bei ungewöhnlichen Spitzen. |
| **Aufgabe** | **Day-ahead-Prognose** (24 Stundenwerte) des Quartierverbrauchs plus **Anomalieerkennung** bei Lastspitzen und Ausfällen. |
| **Daten** | **OPSD Household Data**: 11 Gebäude in Süddeutschland (6 Wohnungen, 3 Gewerbe, 2 Schulen), Auflösung 1/15/60 Min., CC BY 4.0, 60-Min.-Datei 15 MB · optional Wetter (DWD Open Data) · Amprion-Last aus Lab 05 zum Vergleich |
| **Methoden** | Saisonal-naive Baselines, MSTL/ETS (statsforecast), LightGBM mit Lag- und Kalendermerkmalen, optional TFT/Prophet · Isolation Forest oder Autoencoder auf Residuen |
| **Twist** | **Datenschutz:** Smart-Meter-Kurven verraten Anwesenheit und Gewohnheiten → Aggregation und Datenminimierung als Designentscheidung, Prognosegüte je Aggregationsgrad messen |
| **EU AI Act** | **minimal** – Planungsprognose ist kein Sicherheitsbauteil (Anh. III Nr. 2) · DSGVO relevant |

## Profil

| | |
|---|---|
| Programmieraufwand | ●●●○○ |
| Datenzugang (Risiko) | ●○○○○ |
| Rechenbedarf | ●●○○○ |
| Doku & Compliance | ●●○○○ |
| Domänenwissen | ●●○○○ |

**Passt, wenn …**

- Lab 05 lief gut und Sie wollen Zeitreihen vertiefen
- Interesse an Energiewirtschaft und Netzbetrieb

**Kernfrage** Wie genau lässt sich ein Quartier vorhersagen – und wie viel Privatsphäre kostet das?

# Thema 1 · End-to-End-Pfad

Was an jeder Station konkret zu tun ist

## 1 Daten

- 60-Min.-Datei laden, Gebäude zum Quartier aggregieren
- Zählerstände prüfen: kumuliert → Differenzen bilden
- Lücken, Zählersprünge, Sommerzeit bereinigen
- Rohdaten und Pipeline mit DVC versionieren

## 2 Modell

- Backtest mit rollierendem Ursprung (Gerüst aus Lab 05)
- Messlatte: Vortag/Vorwoche saisonal naiv
- MSTL und LightGBM, Metriken MAE und MASE
- optional: Quantile + Pinball-Loss

## 3 Deployment

- FastAPI: /forecast liefert 24 Werte + Intervall
- täglicher Batch-Lauf als Skript
- Dockerfile, Tests mit pytest

## 4 Monitoring

- Bias des Residuums über die Zeit
- Drift-Szenarien: Ferien, neuer Großverbraucher
- Anomalie-Alarm mit begründeter Schwelle

## 5 Verantwortung

- SHAP am LightGBM: welche Lags, welche Kalendermerkmale?
- DSGVO-Konzept: Aggregationsgrad, Speicherdauer
- Model Card + AI-Act-Einordnung

### Basis-Variante · eigener Rechner

Alle Verfahren laufen auf dem Laptop in Sekunden bis wenigen Minuten; 60-Min.- oder 15-Min.-Datei genügen.

### Ausbau · optional

Globales TFT/N-BEATS über alle Gebäude (Cluster) · Wetterprognose als Kovariate · 1-Min.-Daten (851 MB) für Kurzfristprognose.

# Thema 1 · Erfolg und Risiken

Woran Sie messen, ob Sie auf Kurs sind – und wo Projekte typischerweise hängen bleiben

## Mindestziel

- Backtest mit Baseline-Vergleich – LightGBM oder MSTL schlägt saisonal naiv
- Service liefert Day-ahead-Prognose im Container
- Anomalien markiert, Schwelle begründet
- DSGVO- und AI-Act-Einordnung, Model Card

## Ambitioniert

- Globales Modell über mehrere Gebäude vs. lokale Modelle
- Probabilistische Prognose mit Pinball-Loss
- Privacy-Experiment: Fehler je Aggregationsgrad
- Drift-Alarm mit Re-Training-Regel

## Typische Stolpersteine

- Leakage durch Lags kürzer als der Horizont (siehe Lab 05)
- kumulierte Zählerstände als Verbrauch interpretiert
- Zeitzonen und Sommerzeit
- viele Modelle, aber kein sauberer Backtest

## Erste Schritte nach dem Kickoff

1. Datenpaket laden, Gebäude und Zeitraum festlegen
2. Backtest aus Lab 05 auf die Quartierlast übertragen
3. Baseline-Fehler als Messlatte ins README schreiben

## Einstieg und Quellen

- data.open-power-system-data.org/household_data
- Hyndman & Athanasopoulos, FPP3: otexts.com/fpp3 (Kap. 5, 9, 12)
- Lab 05 (Backtest, LightGBM-Merkmale, Isolation Forest)
- opendata.dwd.de (Wetterdaten)

# Thema 2

## Klinik-Triage-Assistent: Dringlichkeit in der Notaufnahme

**Kernfrage** Darf eine KI mitentscheiden, wer in der Notaufnahme zuerst behandelt wird – und unter welchen Bedingungen?

# Thema 2 · Steckbrief

Bei Ankunft vergibt die Pflege eine Dringlichkeitsstufe – ein Assistent soll einen begründeten Vorschlag machen

| | |
|---|---|
| **Szenario** | In der Notaufnahme ordnet die Pflege jede ankommende Person einer Dringlichkeitsstufe zu (Emergency Severity Index, ESI 1–5). Der Assistent macht aus Leitsymptom und Vitalwerten einen Vorschlag. |
| **Aufgabe** | **Mehrklassen-Klassifikation** der Triage-Stufe aus **Freitext + Vitalwerten**. Untertriage (zu niedrige Stufe) ist besonders teuer. |
| **Daten** | **MIMIC-IV-ED** (PhysioNet): > 400 000 Notaufnahme-Aufenthalte, Tabelle triage mit Leitsymptom, Temperatur, Puls, Atemfrequenz, $SpO_2$, Blutdruck, Schmerz, Stufe · **Zugang nur nach Credentialing** (Konto, CITI-Kurs, Nutzungsvereinbarung) · frei: Demo mit 100 Patient:innen |
| **Methoden** | Text-Embeddings des Leitsymptoms (MiniLM) + Vitalwerte → LightGBM oder logistische Regression · kostensensitive Bewertung, Kalibrierung |
| **Twist** | **Hochrisiko-System:** Risikomanagement, Daten-Governance, menschliche Aufsicht und ausführliche Model Card sind Pflichtbestandteile – Dokumentationsaufwand erheblich |
| **EU AI Act** | **hoch** – Anh. III Nr. 5(d) Triage · ggf. zusätzlich Medizinprodukt (Anh. I, MDR) |

## Profil

| | |
|---|---|
| Programmieraufwand | ●●●○○ |
| Datenzugang (Risiko) | ●●●●● |
| Rechenbedarf | ●●○○○ |
| Doku & Compliance | ●●●●● |
| Domänenwissen | ●●●●○ |

**Passt, wenn …**

- Interesse an Medizin und gründliches Dokumentieren liegt der Gruppe
- Zugang wird sofort beantragt – nicht erst nach der Wahl

**Kernfrage** Darf eine KI mitentscheiden, wer in der Notaufnahme zuerst behandelt wird – und unter welchen Bedingungen?

# Thema 2 · End-to-End-Pfad

Was an jeder Station konkret zu tun ist

### 1 Daten

- Credentialing + Nutzungsvereinbarung
- edstays und triage verknüpfen, Leitsymptome bereinigen
- Split nach Person (subject_id), nicht nach Zeile
- Daten nur lokal – nie ins Git, DVC mit lokalem Remote

### 2 Modell

- Baseline: Regeln auf Vitalwerten, Mehrheitsklasse
- Embeddings einmal berechnen und cachen
- LightGBM, Klassenungleichgewicht behandeln
- Makro-F1, Untertriage-Rate, Konfusionsmatrix

### 3 Deployment

- FastAPI /triage: Stufe + Wahrscheinlichkeiten
- Ausgabe klar als Vorschlag gekennzeichnet
- jede Anfrage protokollieren (Art. 12)

### 4 Monitoring

- Drift in Vitalwerten und Leitsymptomen (z. B. Grippesaison)
- Kalibrierung über die Zeit prüfen

### 5 Verantwortung

- SHAP für Vitalwerte, Wortbeiträge für Text
- Fairness über Geschlecht und Alter
- Risikoanalyse (Art. 9), Aufsichtskonzept (Art. 14)
- vollständige Model Card

### Basis-Variante · eigener Rechner

Subset ≤ 100 000 Aufenthalte; MiniLM-Embeddings einmal auf CPU berechnen und cachen, danach Training in Minuten.

### Ausbau · optional

Fine-Tuning eines klinischen BERT-Modells auf dem Leitsymptom (Cluster) · Vergleich eingefrorene Embeddings vs. Fine-Tuning.

# Thema 2 · Erfolg und Risiken

Woran Sie messen, ob Sie auf Kurs sind – und wo Projekte typischerweise hängen bleiben

## Mindestziel

- Modell schlägt die Vitalwert-Baseline, Untertriage-Rate berichtet
- Service mit Protokollierung und Vorschlags-Hinweis
- Hochrisiko-Dokumentation: Risikoanalyse, Aufsicht, Model Card
- Fairness-Metriken über mindestens ein Merkmal

## Ambitioniert

- Kalibrierte Wahrscheinlichkeiten, Schwelle gegen Untertriage optimiert
- Fairness-Analyse mit Gegenmaßnahme vorher/nachher
- vollständige Prüfung von Art. 6 Abs. 3 und Art. 9–15
- Konzept für menschliche Aufsicht im Klinikablauf

## Typische Stolpersteine

- Zugang kommt zu spät – ohne Zugang bis Checkpoint 1 Plan B mit mir absprechen
- Leakage: dieselbe Person in Training und Test
- uneinheitliche Abkürzungen im Leitsymptom
- Daten an ChatGPT & Co. senden – laut Nutzungsvereinbarung verboten

## Erste Schritte nach dem Kickoff

1. Heute: PhysioNet-Konto anlegen, CITI-Kurs starten
2. Demo-Datensatz laden und die Pipeline daran bauen
3. Hochrisiko-Folien aus dem EU-AI-Act-Primer durcharbeiten

## Einstieg und Quellen

- physionet.org/content/mimic-iv-ed · Demo: physionet.org/content/mimic-iv-ed-demo
- PhysioNet: Responsible use of MIMIC data with online services (z. B. GPT)
- VO (EU) 2024/1689, Art. 6, 9–15, Anh. III Nr. 5
- Lab 03 (MiniLM-Embeddings), Lab 05 (LightGBM)

# Thema 3

## Recruiting-Filter mit Fairness-Audit

**Kernfrage** Lässt sich ein Bewerbungsfilter fair bauen – oder sollte man ihn gar nicht einsetzen?

Thema 1 – Thema 2 – **Thema 3** – Thema 4 – Thema 5 – Thema 6 – Thema 7 – Thema 8

# Thema 3 · Steckbrief

Ein Unternehmen will Bewerbungsprofile automatisch vorsortieren – Sie prüfen, ob das fair geht

| | |
|---|---|
| **Szenario** | Ein Unternehmen erhält Tausende Profile und will sie automatisch Berufsfeldern zuordnen und vorfiltern. Bekanntes Gegenbeispiel: Amazon stoppte 2018 ein Tool, das Bewerbungen von Frauen schlechter bewertete. |
| **Aufgabe** | **Text-Klassifikation** (Berufsfeld aus Kurzbiografie) plus **systematischer Fairness-Audit** über Geschlecht – mit einer begründeten Entscheidung, ob das System einsetzbar ist. |
| **Daten** | **Bias in Bios** (De-Arteaga et al. 2019): ≈ 396 000 englische Kurzbiografien, 28 Berufe, Geschlechtslabel, MIT-Lizenz, Hugging Face LabHC/bias_in_bios · Subset wählen, z. B. 5 Berufe · Alter nicht enthalten → nur kontrafaktisch testbar |
| **Methoden** | TF-IDF + logistische Regression, MiniLM-Embeddings, optional DistilBERT (Lab 03) · SHAP/Wortgewichte · Demographic Parity, Equal Opportunity, kontrafaktischer Pronomentausch · Mitigation (Fairlearn) |
| **Twist** | **Würde als Hochrisiko eingestuft** → Diskussion, ob und unter welchen Auflagen das System überhaupt einsetzbar ist; zusätzlich AGG (Gleichbehandlung) |
| **EU AI Act** | **hoch** – Anh. III Nr. 4(a) · Profiling → keine Ausnahme nach Art. 6 Abs. 3 |

## Profil

| | |
|---|---|
| Programmieraufwand | ●●●○○ |
| Datenzugang (Risiko) | ●○○○○ |
| Rechenbedarf | ●●○○○ |
| Doku & Compliance | ●●●●● |
| Domänenwissen | ●●○○○ |

**Passt, wenn …**

- Interesse an NLP, Ethik und Recht
- Gruppe mit Lehreinheit Fairness & Robustheit kann Wissen doppelt nutzen

**Kernfrage** Lässt sich ein Bewerbungsfilter fair bauen – oder sollte man ihn gar nicht einsetzen?

# Thema 3 · End-to-End-Pfad

Was an jeder Station konkret zu tun ist

## 1 Daten

- Subset ziehen, Klassenverteilung je Geschlecht prüfen
- Datasheet: Herkunft, Labelbildung, Grenzen
- Geschlecht ist binär und aus Pronomen abgeleitet – dokumentieren
- Versionieren mit DVC

## 2 Modell

- Baseline TF-IDF + logistische Regression
- MiniLM-Embeddings, optional DistilBERT
- Makro-F1 und Trefferquote (TPR) je Gruppe

## 3 Deployment

- FastAPI /screen: Text → Berufsfeld + Score
- Ausgabe nur als Empfehlung, Begründung mitliefern
- Anfragen protokollieren

## 4 Monitoring

- Fairness-Metriken als laufende Kennzahl
- Sprach- und Verteilungsdrift neuer Profile

## 5 Verantwortung

- Audit-Bericht: Metriken, Ursachen, Mitigation
- Vorher/Nachher-Vergleich
- Art. 9–15-Checkliste, Model Card
- Empfehlung: einsetzen ja/nein, mit Auflagen

### Basis-Variante · eigener Rechner

TF-IDF und Embeddings auf CPU in Minuten; DistilBERT nur auf einem Subset wie in Lab 03.

### Ausbau · optional

Fine-Tuning größerer Modelle (Cluster) · ein LLM als Zero-Shot-Screener per Namens- und Pronomentausch auditieren.

# Thema 3 · Erfolg und Risiken

Woran Sie messen, ob Sie auf Kurs sind – und wo Projekte typischerweise hängen bleiben

## Mindestziel

- Klassifikator mit Baseline-Vergleich
- Fairness-Metriken je Geschlecht, sauber interpretiert
- mindestens eine Mitigation mit Vorher/Nachher
- begründete Einsetzbarkeitsentscheidung + Model Card

## Ambitioniert

- Kontrafaktischer Test (Pronomen, Namen, Altersangaben)
- Trade-off-Kurve Genauigkeit vs. Fairness
- Vergleich mit einem Zero-Shot-LLM
- Konzept für menschliche Aufsicht im Prozess

## Typische Stolpersteine

- Pronomen im Text verraten das Merkmal (Proxy)
- Fairness-Metriken widersprechen sich – das ist kein Fehler, sondern ein Satz der Theorie
- nur Accuracy berichten
- binäre Geschlechtslabels unkritisch übernehmen

## Erste Schritte nach dem Kickoff

1. Datensatz laden, Berufe und Subset festlegen
2. Baseline trainieren und TPR je Geschlecht ausgeben
3. Barocas/Hardt/Narayanan Kap. 3 lesen (Gruppenkriterien)

## Einstieg und Quellen

- huggingface.co/datasets/LabHC/bias_in_bios
- De-Arteaga et al. (2019): Bias in Bios, FAccT
- Barocas, Hardt, Narayanan: fairmlbook.org · fairlearn.org
- Dastin (2018), Reuters: Amazon scraps secret AI recruiting tool

# Thema 4

## Predictive Maintenance für Industrieanlagen

**Kernfrage** Wie viele Betriebszyklen bleiben einer Komponente – und wann lohnt sich die Wartung?

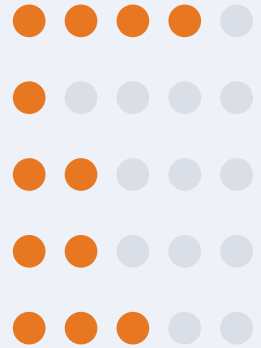
Thema 1 – Thema 2 – Thema 3 – **Thema 4** – Thema 5 – Thema 6 – Thema 7 – Thema 8

# Thema 4 · Steckbrief

Warten, bevor etwas kaputtgeht – aber nicht so früh, dass man intakte Teile wegwirft

| | |
|---|---|
| **Szenario** | Ein Betreiber von Turbofan-Triebwerken – übertragbar auf Pumpen, Spindeln, Getriebe – will Wartung planen: nicht zu früh (Kosten), nicht zu spät (Ausfall). |
| **Aufgabe** | **Restlebensdauer** (Remaining Useful Life, RUL) je Einheit aus Sensorverläufen vorhersagen, Ausfallwahrscheinlichkeit über die Zeit schätzen, Wartungsalarm auslösen. |
| **Daten** | **NASA C-MAPSS**: simulierte Triebwerksdegradation, Teildatensätze FD001–FD004, je Zyklus 3 Betriebseinstellungen + 21 Sensoren; FD001: 100 Trainings-Triebwerke, ein Betriebs- und ein Fehlermodus; wenige MB · ergänzend PHM-Society-Challenges |
| **Methoden** | Fenster-Merkmale + LightGBM, LSTM oder 1D-CNN auf Zeitfenstern, Survival-Analyse (Kaplan-Meier, Cox; lifelines) · RMSE + asymmetrischer Score (späte Prognose teurer) |
| **Twist** | **Edge-Deployment** simulieren: ONNX-Export, CPU-Inferenz mit onnxruntime, Latenz und Modellgröße messen – kein Raspberry Pi nötig |
| **EU AI Act** | **meist minimal** – reine Wartungsprognose ohne Sicherheitsfunktion; Maschinen seit Omnibus über die Maschinenverordnung |

## Profil




**Passt, wenn …**

- Maschinenbau, Mechatronik, E-Technik
- Lust auf Zeitreihen und auf Deployment-Technik

**Kernfrage** Wie viele Betriebszyklen bleiben einer Komponente – und wann lohnt sich die Wartung?

# Thema 4 · End-to-End-Pfad

Was an jeder Station konkret zu tun ist

## 1 Daten

- mit FD001 starten, später FD002–FD004
- RUL-Label bilden, oben kappen (z. B. 125 Zyklen)
- konstante Sensoren entfernen, je Betriebsmodus normieren
- Split nach Triebwerk, DVC

## 2 Modell

- Baseline: mittlere Lebensdauer, lineare Regression
- LightGBM auf Fenster-Merkmalen
- LSTM auf 30-Zyklen-Fenstern
- Survival-Kurven je Einheit

## 3 Deployment

- Export nach ONNX, Service mit onnxruntime
- schlanker Container ohne PyTorch
- Latenz (p50/p95) und Größe messen

## 4 Monitoring

- Sensor-Offset simulieren
- FD001 → FD002 als Drift: neue Betriebsbedingungen
- Alarm und Re-Training-Regel

## 5 Verantwortung

- SHAP: Welche Sensoren treiben die Prognose?
- Kostenmodell: Wartung zu früh vs. zu spät
- AI-Act- und Maschinenverordnungs-Einordnung, Model Card

### Basis-Variante · eigener Rechner

Alles auf CPU: LightGBM in Sekunden, ein kleines LSTM auf FD001 in wenigen Minuten.

### Ausbau · optional

Transformer auf allen vier Teildatensätzen (Cluster) · INT8-Quantisierung und Vergleich der Latenz.

# Thema 4 · Erfolg und Risiken

Woran Sie messen, ob Sie auf Kurs sind – und wo Projekte typischerweise hängen bleiben

## Mindestziel

- RUL-Modell schlägt die Baseline (RMSE und Score)
- ONNX-Service im Container mit Latenzmessung
- Drift-Szenario mit Detektor
- Model Card und Einordnung

## Ambitioniert

- Survival-Analyse mit Unsicherheitsband
- Wartungsregel mit kostenoptimaler Schwelle
- FD002/FD004: mehrere Betriebsmodi
- Quantisierung mit Genauigkeits-/Latenz-Abwägung

## Typische Stolpersteine

- Split nach Zeilen statt nach Triebwerk (Leakage)
- Test-RUL gilt nur für den letzten Zyklus jeder Einheit
- ONNX-Export des LSTM: dynamische Achsen
- Normierung über Betriebsmodi hinweg

## Erste Schritte nach dem Kickoff

1. FD001 laden, RUL-Label bauen, Sensorverläufe plotten
2. Baseline und LightGBM mit Split nach Triebwerk
3. ONNX-Export eines Minimalmodells früh testen

## Einstieg und Quellen

- NASA Prognostics Center of Excellence: Data Set Repository (Turbofan, C-MAPSS)
- Saxena et al. (2008): Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation, PHM
- lifelines.readthedocs.io · onnxruntime.ai
- Lab 05 (LightGBM, LSTM)

# Thema 5

## RAG-basierter Compliance-Assistent

**Kernfrage** Kann ein Sprachmodell Fragen zum EU AI Act zuverlässig beantworten – und woran merkt man, wenn es halluziniert?

Thema 1 – Thema 2 – Thema 3 – Thema 4 – **Thema 5** – Thema 6 – Thema 7 – Thema 8

# Thema 5 · Steckbrief

Fragen zu AI Act und DSGVO beantworten – mit wörtlicher Quelle statt erfundener Paragrafen

| | |
|---|---|
| **Szenario** | Ein KMU fragt: „Fällt unser System unter den AI Act, und was müssen wir tun?“ Die Verordnung hat 113 Artikel und 13 Anhänge – und wurde 2026 durch den Digital Omnibus geändert. |
| **Aufgabe** | **Frage-Antwort-System** über AI Act und DSGVO mit **Quellenangabe** (Artikel, Absatz); Halluzinationen messen und reduzieren. |
| **Daten** | **EUR-Lex**: VO (EU) 2024/1689, VO (EU) 2026/1744 (Omnibus), VO (EU) 2016/679 (DSGVO) – amtliche Texte, frei weiterverwendbar · eigenes Eval-Set: 50–100 Fragen mit Soll-Antwort und Soll-Quelle |
| **Methoden** | Chunking nach Artikel/Absatz, mehrsprachige MiniLM-Embeddings, Vektor-DB lokal (Chroma/FAISS), optional BM25-Hybrid · LLM per API oder lokal ≤ 1 B · Eval: Recall@k, Treue zur Quelle, LLM-as-a-Judge |
| **Twist** | **Re-Indexierung:** Die Rechtslage ändert sich – Ihre Pipeline erkennt eine neue Fassung, indexiert neu und lässt das Eval-Set automatisch als Regressionstest laufen |
| **EU AI Act** | **Transparenz** – Art. 50 Abs. 1: Nutzer müssen wissen, dass sie mit KI interagieren · keine Rechtsberatung |

## Profil

| | |
|---|---|
| Programmieraufwand | ●●●●○ |
| Datenzugang (Risiko) | ●○○○○ |
| Rechenbedarf | ●●○○○ |
| Doku & Compliance | ●●●○○ |
| Domänenwissen | ●●●○○ |

**Passt, wenn …**

- Interesse an LLM-Engineering und Evaluation
- Lab 04 (Eval-Setup, LLM-as-a-Judge) hat Spaß gemacht

**Kernfrage** Kann ein Sprachmodell Fragen zum EU AI Act zuverlässig beantworten – und woran merkt man, wenn es halluziniert?

# Thema 5 · End-to-End-Pfad

Was an jeder Station konkret zu tun ist

## 1 Daten

- EUR-Lex-HTML parsen
- Struktur als Metadaten: Kapitel, Artikel, Absatz, Erwägungsgrund
- Ausgangsfassung vs. Änderungsakt unterscheiden
- Rohtexte und Index mit DVC versionieren

## 2 Modell

- Baseline: LLM ohne Retrieval
- Retriever dense, BM25, hybrid vergleichen
- Prompt mit Zitierpflicht
- Eval-Set mit Soll-Quellen

## 3 Deployment

- FastAPI /ask → Antwort + Quellen-Links
- Kosten und Tokens je Anfrage loggen
- optional einfache Weboberfläche

## 4 Monitoring

- Eval-Score nach jeder Re-Indexierung
- Kosten, Latenz, Anteil „keine Antwort“
- Änderungen der Quelltexte erkennen

## 5 Verantwortung

- Halluzinationsanalyse mit Beispielen
- Transparenzhinweis (Art. 50), Disclaimer
- Model Card bzw. System Card

### Basis-Variante · eigener Rechner

Embeddings auf CPU, Vektor-DB lokal; LLM per API mit festem Budget oder lokal Qwen2.5-0.5B / SmolLM2-360M.

### Ausbau · optional

Re-Ranker (Cross-Encoder) · größeres lokales Modell auf dem Cluster · Vergleich Qualität vs. Kosten je Modell.

# Thema 5 · Erfolg und Risiken

Woran Sie messen, ob Sie auf Kurs sind – und wo Projekte typischerweise hängen bleiben

## Mindestziel

- Eval-Set ≥ 50 Fragen, Vergleich mit/ohne Retrieval
- Quellenangaben automatisch auf Korrektheit geprüft
- Re-Index-Pipeline mit DVC
- Service mit Kostenlogging, Transparenzhinweis

## Ambitioniert

- LLM-as-a-Judge gegen eigene Handbewertung validiert
- Hybrid-Retrieval + Re-Ranker
- Regressionstest läuft automatisch bei neuer Fassung
- Kosten-Qualitäts-Vergleich mehrerer Modelle

## Typische Stolpersteine

- Chunks zerschneiden Absätze und Verweise
- Eval-Set zu klein oder zu leicht
- LLM-as-a-Judge ungeprüft übernehmen
- API-Kosten ohne Logging

## Erste Schritte nach dem Kickoff

1. Texte von EUR-Lex holen, Struktur extrahieren
2. 20 Eval-Fragen schreiben, bevor das System existiert
3. Baseline ohne Retrieval messen

## Einstieg und Quellen

- eur-lex.europa.eu: 32024R1689 · 32016R0679 · Omnibus 2026/1744
- Lewis et al. (2020): Retrieval-Augmented Generation, NeurIPS
- Es et al. (2023): RAGAS · Zheng et al. (2023): LLM-as-a-Judge
- Lab 04 (Eval-Setup) · docs.trychroma.com

# Thema 6

## Computer-Vision-Qualitätskontrolle

**Kernfrage** Wie findet ein Modell Defekte, die es im Training fast nie gesehen hat?

Thema 1 – Thema 2 – Thema 3 – Thema 4 – Thema 5 – **Thema 6** – Thema 7 – Thema 8

# Thema 6 · Steckbrief

Kratzer, Risse, Verfärbungen erkennen – obwohl es fast nur Bilder von Gutteilen gibt

| | |
|---|---|
| **Szenario** | In der Endkontrolle prüfen Menschen Oberflächen von Holz, Leder oder Metallteilen. Defekte sind selten: Es gibt viele Bilder von Gutteilen, aber kaum Fehlerbilder. |
| **Aufgabe** | **Defekterkennung** (gut/defekt) plus **Lokalisierung** als Heatmap, trainiert überwiegend auf Gutteilen; robust gegen wechselnde Beleuchtung. |
| **Daten** | **MVTec AD**: 15 Kategorien (Texturen wie wood, leather, tile; Objekte wie metal_nut, screw, bottle), 5 354 Bilder, Training nur fehlerfrei, Test mit Pixelmasken · CC BY-NC-SA 4.0 · voll 4,9 GB → 1–2 Kategorien (≈ 300 MB), Download per Formular |
| **Methoden** | Transfer Learning (ResNet-18 wie beim Trägermodell) als Merkmalsextraktor · Autoencoder (Rekonstruktionsfehler) vs. PaDiM/PatchCore (anomalib) · AUROC auf Bild- und Pixelebene |
| **Twist** | **Drift-Monitoring bei wechselnder Beleuchtung** simulieren – methodisch direkt anschlussfähig an das Trägermodell-Lab im Thema Monitoring & Drift |
| **EU AI Act** | **minimal** – solange das System kein Sicherheitsbauteil ist |

## Profil

| | |
|---|---|
| Programmieraufwand | ●●●○○ |
| Datenzugang (Risiko) | ●●○○○ |
| Rechenbedarf | ●●●○○ |
| Doku & Compliance | ●●○○○ |
| Domänenwissen | ●●○○○ |

**Passt, wenn …**

- CNNs & Computer Vision lag Ihnen
- Sie wollen den Trägermodell-Code direkt weiterverwenden

**Kernfrage** Wie findet ein Modell Defekte, die es im Training fast nie gesehen hat?

# Thema 6 · End-to-End-Pfad

Was an jeder Station konkret zu tun ist

### 1 Daten

- 1–2 Kategorien wählen, Bildgröße 224
- Testdefekte nie ins Training
- Daten nicht ins Repo: Download-Skript + DVC
- eigenen Validierungssplit bilden

### 2 Modell

- Baseline: kNN auf ImageNet-Merkmalen
- Autoencoder
- PaDiM oder PatchCore
- AUROC, Schwelle für Ausschussrate

### 3 Deployment

- FastAPI /inspect: Score + Heatmap-PNG
- Container nach Trägermodell-Vorlage
- Tests mit Beispielbildern

### 4 Monitoring

- Drift-Strom: Helligkeit, Unschärfe, JPEG
- KS-Test/PSI auf Embeddings und Scores
- Alarm und Re-Training-Auslöser

### 5 Verantwortung

- Heatmaps und Grad-CAM als Erklärung
- Fehlerkosten: Schlupf vs. Pseudoausschuss
- Model Card

### Basis-Variante · eigener Rechner

1–2 Kategorien; Merkmalsextraktion mit ResNet-18 auf CPU in wenigen Minuten, Merkmale cachen.

### Ausbau · optional

Alle 15 Kategorien, größere Backbones für PatchCore (Cluster) · Robustheitskurve über viele Drift-Stufen.

# Thema 6 · Erfolg und Risiken

Woran Sie messen, ob Sie auf Kurs sind – und wo Projekte typischerweise hängen bleiben

## Mindestziel

- Zwei Verfahren per AUROC verglichen
- Service liefert Score und Heatmap
- Drift-Simulation mit Detektor
- Schwelle über Fehlerkosten begründet, Model Card

## Ambitioniert

- Pixel-AUROC: Lokalisierung bewertet
- Robustheitskurve über Beleuchtungsstufen
- Re-Training-Regel nach Drift-Alarm
- Vergleich Textur- vs. Objektkategorie

## Typische Stolpersteine

- Defektbilder versehentlich im Training
- Autoencoder zu groß – rekonstruiert auch Defekte
- Arbeitsspeicher bei hochaufgelösten Bildern
- Lizenz NC-SA beachten, Daten nicht weiterverteilen

## Erste Schritte nach dem Kickoff

1. Datensatz anfordern, 1–2 Kategorien laden
2. Trägermodell-Code als Merkmalsextraktor wiederverwenden
3. kNN-Baseline und AUROC als Messlatte

## Einstieg und Quellen

- mvtec.com/company/research/datasets/mvtec-ad
- Bergmann et al. (2019): MVTec AD, CVPR · Roth et al. (2022): PatchCore, CVPR
- Defard et al. (2021): PaDiM · anomalib.readthedocs.io
- Lab 02 + Trägermodell, Autoencoder-Folien Zeitreihen

# Thema 7

## Multi-Agent Customer-Service

**Kernfrage** Wann löst ein Agentensystem Kundenanliegen wirklich – und wann muss ein Mensch übernehmen?



# Thema 7 · Steckbrief

Wo ist meine Bestellung? Wie storniere ich? – Agenten mit Werkzeugen beantworten Standardanfragen

| | |
|---|---|
| **Szenario** | Ein Onlinehändler beantwortet täglich Hunderte gleichartige Anfragen zu Bestellstatus, Stornierung, Erstattung und Versand. |
| **Aufgabe** | **LLM-Agentensystem**: Ein Router erkennt das Anliegen, Spezialisten-Agenten nutzen **Werkzeuge** (Bestellungen abfragen, Storno anlegen, FAQ per RAG) und übergeben bei Unsicherheit an einen Menschen. |
| **Daten** | **Bitext Customer Support**: 26 872 Anfrage-Antwort-Paare, 27 Intents in 10 Kategorien (ORDER, REFUND, SHIPPING …), CDLA-Sharing-1.0, Hugging Face · eigene synthetische Bestelldatenbank (SQLite) + FAQ-Texte |
| **Methoden** | Router-Baseline: Embeddings + logistische Regression · Tool-Use/Function Calling · Framework (z. B. LangGraph, smolagents) oder eigene Schleife · RAG über FAQ · Szenario-Eval |
| **Twist** | **Transparenzpflicht** nach Art. 50 diskutieren und umsetzen; DSGVO bei Kundendaten; Prompt-Injection gegen die Werkzeuge testen |
| **EU AI Act** | **Transparenz** – Art. 50 Abs. 1 (Chatbot) · DSGVO: Kundendaten |

## Profil

| | |
|---|---|
| Programmieraufwand | ●●●●● |
| Datenzugang (Risiko) | ●○○○○ |
| Rechenbedarf | ●●○○○ |
| Doku & Compliance | ●●●○○ |
| Domänenwissen | ●○○○○ |

**Passt, wenn …**

- Mindestens zwei sichere Programmierer:innen in der Gruppe
- Interesse an LLM-Engineering und Software-Architektur

**Kernfrage** Wann löst ein Agentensystem Kundenanliegen wirklich – und wann muss ein Mensch übernehmen?

# Thema 7 · End-to-End-Pfad

Was an jeder Station konkret zu tun ist

### 1 Daten

- Bitext-Subset nach Intents
- synthetische Kunden und Bestellungen (z. B. Faker)
- ≥ 50 Testdialoge mit erwarteter Aktion
- alles mit DVC versionieren

### 2 Modell

- Router-Baseline ohne LLM
- Agent mit ≥ 2 Werkzeugen
- Übergaberegel an Menschen
- temperature 0 für reproduzierbare Läufe

### 3 Deployment

- FastAPI /chat mit Sitzungs-ID
- Werkzeuge als interne Funktionen
- Container, Tests der Werkzeuge

### 4 Monitoring

- Kosten und Tokens je Anfrage
- Werkzeug-Fehlerrate, Übergabequote
- Intent-Drift

### 5 Verantwortung

- KI-Hinweis im Dialog (Art. 50)
- nur synthetische Kundendaten
- Prompt-Injection-Tests, System Card

### Basis-Variante · eigener Rechner

Router und Werkzeuge lokal; LLM per API mit festem Budget – lokale Modelle ≤ 1 B beherrschen Tool-Use nur eingeschränkt.

### Ausbau · optional

Lokales 7-B-Modell auf dem Cluster · Vergleich Kosten/Qualität zwischen API und eigenem Modell (Build vs. Buy).

# Thema 7 · Erfolg und Risiken

Woran Sie messen, ob Sie auf Kurs sind – und wo Projekte typischerweise hängen bleiben

## Mindestziel

- Router-Baseline + Agent mit ≥ 2 Werkzeugen
- Szenario-Eval: Erfolgsrate und Kosten je Anfrage
- Übergabe an Menschen umgesetzt
- Service, Transparenz- und DSGVO-Einordnung

## Ambitioniert

- Multi-Agent vs. Single-Agent im Vergleich
- Red-Teaming mit Prompt-Injection
- Kosten-Qualitäts-Abwägung API vs. lokal
- Monitoring-Dashboard für Kosten und Übergaben

## Typische Stolpersteine

- Framework-Komplexität frisst die Projektzeit
- Bewertung nach Gefühl statt Eval-Set
- API-Kosten unbeobachtet
- nichtdeterministische Ausgaben

## Erste Schritte nach dem Kickoff

1. Bestelldatenbank und drei Werkzeuge als Python-Funktionen
2. Router-Baseline auf Bitext trainieren
3. 10 Testdialoge mit erwarteter Aktion schreiben

## Einstieg und Quellen

- huggingface.co/datasets/bitext/Bitext-customer-support-llm-chatbot-training-dataset
- Yao et al. (2023): ReAct, ICLR
- Anthropic (2024): Building effective agents
- langchain-ai.github.io/langgraph · huggingface.co/docs/smolagents

# Thema 8

## Eigenes Thema

**Kernfrage** Deckt Ihr Use Case alle fünf Stationen ab – mit Daten, die Sie heute schon haben?

Thema 1 – Thema 2 – Thema 3 – Thema 4 – Thema 5 – Thema 6 – Thema 7 – **Thema 8**

# Thema 8 · Voraussetzungen

Eigene Themen sind willkommen – wenn sie in sieben Wochen auf einem Laptop machbar sind

## Genehmigt wird, wenn …

- alle Stationen sinnvoll abgedeckt sind: Daten, Modell, Deployment, Monitoring, Verantwortung
- die Daten heute vorliegen oder der Zugang bis zum Kickoff gesichert ist
- die Basis-Variante auf der Referenzhardware läuft
- eine AI-Act-Einordnung mit Begründung vorliegt

## Gute Datenquellen

- Hugging Face Datasets, Kaggle, UCI Machine Learning Repository
- GovData (govdata.de), Open Power System Data, DWD Open Data
- Praktikum oder Arbeitgeber – nur mit schriftlicher Freigabe, Daten nie ins öffentliche Repo
- eigene Messungen oder Aufnahmen, sofern ohne Personenbezug

## Ungeeignet

Projekte ohne Vorhersageaufgabe (reines Dashboard) · Daten erst „vielleicht“ verfügbar · Reinforcement Learning ohne Simulator · Training großer Modelle als Kern

# Thema 8 · Antrag auf einer Seite

Diese sieben Punkte beantworten – als PDF oder Teams-Nachricht bis zur Themenwahl

| | | |
|---|---|---|
| 1 | **Use Case** | Wer nutzt das System, welche Entscheidung unterstützt es? |
| 2 | **Daten** | Quelle, Lizenz, Umfang, Zugang bereits gesichert? |
| 3 | **Modell** | Aufgabentyp, Baseline, geplantes Modell, Metrik |
| 4 | **Deployment** | Wie wird das Modell aufgerufen (API, Batch, Edge)? |
| 5 | **Monitoring** | Welche Drift ist realistisch, wie simulieren Sie sie? |
| 6 | **Verantwortung** | AI-Act-Stufe mit Artikel, DSGVO, Fairness-Fragen |
| 7 | **Risiko & Plan B** | Was tun Sie, wenn Daten oder Modell nicht wie geplant funktionieren? |

# Themenwahl: so geht es

Drei Schritte bis zur Sitzung – danach geht es direkt ins Datenkonzept

### 1 In der Gruppe lesen

- Steckbriefe aller Themen durchgehen
- Profil gegen Ihren Kompetenzmix halten
- EU-AI-Act-Primer für Hochrisiko-Themen lesen

### 2 Erst- und Zweitwahl

- je ein Satz Begründung
- Thema 2: Zugang beantragt?
- Thema 8: Antrag beilegen

### 3 Vergabe

- jedes Thema höchstens einmal
- bei Doppelung: Absprache, sonst Los
- Zweitwahl greift automatisch

### Vorbereitung für den Kickoff

Datenquelle herunterladen oder Zugang klären · Repository anlegen · Rollen verteilen: Daten, Modell, Deployment, Verantwortung